Universidad Nacional del Altiplano · Facultad de Ingeniería Estadística e Informática
Curso: Estadística Espacial · Docente: Fred Torres Cruz

Metaanálisis del desempeño de la predicción espacial de variables ambientales mediante geoestadística y aprendizaje automático en regiones montañosas

Propuesta de revisión sistemática con metaanálisis

Colquehuanca Zapana, Kris Ximena
Laura Livise, Yeferson Dariun
Leon Mamani, Obed Eliu
Portillo Machaca, Kevin Pleyer

1. Research gap

En las regiones montañosas, las redes de monitoreo ambiental son escasas, están mal distribuidas y se concentran en las cotas bajas, mientras que la precipitación, la temperatura y la calidad del aire varían de forma marcada con la altitud y el relieve. Para estimar estas variables en ubicaciones sin medición se usan dos familias de métodos: la *geoestadística*, que modela de forma explícita la dependencia espacial (kriging, cokriging, GWR), y el *aprendizaje automático* (Random Forest, SVM, redes neuronales). Ambas incorporan covariables como la elevación y productos satelitales o de reanálisis (CHIRPS, IMERG, ERA5), y sus estimaciones sirven de base para mapear índices de sequía (SPI, SPEI, VCI) asociados a El Niño.

La evidencia comparativa es contradictoria: algunos estudios favorecen los métodos con dependencia espacial y otros al Random Forest. Además, las comparaciones están **fragmentadas** (pocos métodos en una sola cuenca o ciudad, con métricas distintas), la **validación es heterogénea** (la validación cruzada aleatoria puede sobrestimar el desempeño frente a la espacial) y el efecto de la altitud, la densidad de la red y las covariables satelitales **no se ha sintetizado**.

> **Vacío de investigación.** No existe una síntesis cuantitativa que compare el desempeño predictivo de la geoestadística frente al aprendizaje automático para estimar variables ambientales en regiones montañosas, ni que explique cómo varía esa diferencia según la variable estimada, la altitud, la densidad de la red y el esquema de validación.

2. Pregunta de investigación

En regiones montañosas con redes de monitoreo escasas, ¿cómo se compara el desempeño predictivo fuera de muestra de la geoestadística frente al aprendizaje automático para estimar variables ambientales en ubicaciones sin medición, y qué factores explican las diferencias?

3. PICO

Población	Estudios primarios publicados entre 2015 y 2026 que estiman precipitación, temperatura, índices de sequía (SPI, SPEI, VCI) o $PM_{2.5}$ en ubicaciones sin medición, en regiones montañosas (por encima de 1000 m s. n. m.) con redes de monitoreo escasas, y que validan sus predicciones fuera de muestra con estaciones. Los Andes tropicales (Perú, Ecuador y Bolivia) y el Altiplano se analizan como estrato prioritario.
Intervención	Métodos geoestadísticos que modelan de forma explícita la dependencia espacial: kriging ordinario, universal y con deriva externa, regresión-kriging, cokriging, regresión geográficamente ponderada (GWR) y modelos bayesianos espaciales, con o sin covariables (elevación, productos satelitales o de reanálisis).
Comparación	Algoritmos de aprendizaje automático: Random Forest, XGBoost, máquinas de soporte vectorial y redes neuronales, con covariables equivalentes. Los modelos híbridos (por ejemplo, Random Forest con kriging de residuos) se analizan como categoría separada.
Resultado	Desempeño predictivo fuera de muestra. *Principal:* $\ln(\mathrm{RMSE}_{\mathrm{geo}}/\mathrm{RMSE}_{\mathrm{AA}})$, razón adimensional que permite combinar variables en distintas unidades; los valores negativos favorecen a la geoestadística. *Secundarios:* MAE, R^2, KGE, sesgo porcentual y cobertura de los intervalos de predicción.