PREDICCIÓN ESPACIAL DE PM2.5 MEDIANTE GEOESTADÍSTICA Y APRENDIZAJE AUTOMÁTICO

Apellidos y Nombres: Laura Livise Yeferson Dariun

Vacío de investigación

Las redes de monitoreo no cubren todas las ubicaciones de interés, por lo que se utilizan modelos para estimar concentraciones de PM2.5 en lugares sin mediciones. Los estudios comparativos ofrecen resultados diferentes, (Berrocal et al., 2020) encontraron mejor desempeño de métodos que modelan explícitamente la dependencia espacial, mientras que Zhu et al. (2024) observaron ventajas de Random Forest para PM2.5 en Escocia.

Esta discrepancia dificulta establecer en qué condiciones conviene cada enfoque. Los resultados proceden de contextos con distintas redes de estaciones, covariables y procedimientos de evaluación. La brecha propuesta es sintetizar críticamente estas comparaciones, considerando cómo se valida la predicción en ubicaciones excluidas del entrenamiento y cómo las características de la red acompañan las diferencias de desempeño. La revisión buscará identificar condiciones de aplicabilidad y limitaciones de la evidencia, sin presuponer la superioridad universal de un método.

Pregunta de investigación

En datos georreferenciados de PM2.5, ¿cómo se compara el desempeño de los métodos geoestadísticos frente al aprendizaje automático para estimar concentraciones en ubicaciones sin mediciones, considerando los procedimientos de validación y las características de la red de monitoreo?

PICO:

POBLACIÓN	Datos georreferenciados de concentraciones ambientales de PM2.5, obtenidos de redes de estaciones o sensores y utilizados para evaluar predicciones en otras ubicaciones.
INTERVENCIÓN	Métodos geoestadísticos que representan explícitamente la dependencia espacial, como kriging y modelos con covarianza espacial.
COMPARACIÓN	Algoritmos de aprendizaje automático, como Random Forest, soporte vectorial y redes neuronales. Los modelos híbridos se analizarán como categoría separada.
RESULTADOS	Error de predicción fuera de muestra, principalmente RMSE y error absoluto medio (MAE), registrando su definición y escala. Como resultado secundario, incertidumbre predictiva cuando se reporte.

Referencias

Berrocal, V. J., Guan, Y., Muyskens, A., Wang, H., Reich, B. J., Mulholland, J. A., & Chang, H. H. (2020). A comparison of statistical and machine learning methods for creating national daily maps of ambient PM2.5 concentration. *Atmospheric Environment*, *222*. https://doi.org/10.1016/j.atmosenv.2019.117130

Zhu, Q., Lee, D., & Stoner, O. (2024). A comparison of statistical and machine learning models for spatio-temporal prediction of ambient air pollutant concentrations in Scotland. *Environmental and Ecological Statistics*, *31*(4), 1085–1108. https://doi.org/10.1007/s10651-024-00635-5